


ANALISIS DERET WAKTU

Metodologi ARIMA Box-Jenkins

Pemodelan dan peramalan data deret waktu univariat



Pengantar

ARIMA (*Autoregressive Integrated Moving Average*) memodelkan nilai sebuah deret waktu dari nilai-nilai masa lalunya dan galat masa lalunya. Box dan Jenkins (1970) menyusunnya sebagai prosedur **iteratif** empat tahap:

01

Identifikasi

Tentukan orde d , p , dan q dari plot data, ACF, dan PACF.

02

Estimasi

Taksir parameter model, misalnya dengan least squares atau MLE.

03

Cek diagnostik

Uji apakah residual bersifat white noise dan berdistribusi normal.

04

Peramalan

Gunakan model terbaik untuk memprediksi nilai mendatang.

Komponen model ARIMA(p, d, q)

$$\phi(B) (1 - B)^d Z_t = \theta_0 + \theta(B) a_t$$

B: operator backshift ($BZ_t = Z_{t-1}$) · a_t : galat white noise · θ_0 : konstanta

AR(p)

AUTOREGRESSIVE

$$\phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$$

Nilai saat ini dipengaruhi oleh p nilai sebelumnya.

I(d)

INTEGRATED

$$(1 - B)^d Z_t$$

Differencing sebanyak d kali agar stasioner dalam mean.

MA(q)

MOVING AVERAGE

$$\theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots$$

Nilai saat ini dipengaruhi oleh q galat sebelumnya.

Jenis model ARIMA non-musiman

Model	Notasi ARIMA	Bentuk persamaan	Ciri utama
AR(p)	ARIMA(p, 0, 0)	$Z_t = \phi_1 Z_{t-1} + \dots + \phi_p Z_{t-p} + a_t$	PACF terpotong di lag p
MA(q)	ARIMA(0, 0, q)	$Z_t = a_t - \theta_1 a_{t-1} - \dots$ (hingga lag q)	ACF terpotong di lag q
ARMA(p, q)	ARIMA(p, 0, q)	Gabungan suku AR dan MA pada data stasioner	ACF dan PACF turun cepat
ARIMA(p, d, q)	ARIMA(p, d, q)	ARMA(p, q) pada data hasil differencing d kali	Data awal tidak stasioner dalam mean


AR, MA, dan ARMA adalah kasus khusus ARIMA dengan $d = 0$, sehingga hanya berlaku untuk data yang sudah stasioner.

Kasus khusus: white noise dan random walk

White noise

ARIMA(0, 0, 0)

$$Z_t = \mu + a_t$$




Acak murni, stasioner; tidak ada pola yang bisa dimodelkan.

Random walk

ARIMA(0, 1, 0)

$$Z_t = Z_{t-1} + a_t$$




Tidak stasioner; ramalan terbaik = nilai terakhir.

Random walk + drift

ARIMA(0, 1, 0) + c

$$Z_t = c + Z_{t-1} + a_t$$



Tren naik/turun rata-rata sebesar c tiap periode.


ARIMA(0, 1, 1) setara dengan simple exponential smoothing.

ARIMA(0, 2, 2) setara dengan metode tren linier Holt.

Uji stasioneritas (1): correlogram ACF

Stasioner: AR(1), $\phi_1 = 0,7$


STASIONER



ACF turun cepat ke nol: $\hat{\rho}_1 = 0,76$, lalu masuk batas $\pm 2/\sqrt{n}$ setelah beberapa lag.

Tidak stasioner: random walk

TIDAK STASIONER



ACF turun sangat lambat, hampir linear: $\hat{\rho}_1 = 0,97$, $\hat{\rho}_{10} = 0,73$.

1

Buat plot ACF sampai lag ± 20 (atau $3s$ untuk data musiman).

2

Stasioner bila ACF turun cepat (dies down) dan masuk batas $\pm 2/\sqrt{n}$.

3

Tidak stasioner dalam mean bila $\hat{\rho}_1 \approx 1$ dan ACF turun lambat.

Uji stasioneritas (2): Augmented Dickey-Fuller (ADF)

Hipotesis

$H_0: \gamma = 0$, terdapat akar unit (tidak stasioner)

$H_1: \gamma < 0$, data stasioner

Persamaan regresi ADF

$$\Delta Z_t = \alpha + \beta t + \gamma Z_{t-1} + \sum \delta_i \Delta Z_{t-i} + a_t$$

Statistik uji: $\tau = \hat{\gamma} / SE(\hat{\gamma})$, dengan $\Delta Z_t = Z_t - Z_{t-1}$

Nilai kritis MacKinnon ($\alpha = 5\%$, sampel besar)

Bentuk regresi	Nilai kritis τ
Tanpa konstanta	-1,94
Dengan konstanta (α)	-2,86
Konstanta + tren ($\alpha + \beta t$)	-3,41



Prosedur pengujian

- 1 Tentukan bentuk regresi dari time series plot (konstanta / tren).
- 2 Pilih jumlah lag ΔZ_{t-i} , biasanya otomatis dengan AIC.
- 3 Hitung τ dan p-value (software: R, Python, Minitab, EViews).
- 4 Tolak H_0 bila $\tau < \text{nilai kritis}$ atau $p\text{-value} < \alpha \rightarrow$ data stasioner.
- 5 Jika H_0 gagal ditolak $\rightarrow$ lakukan differencing, lalu uji ulang.

Contoh: mana yang stasioner dan mana yang tidak?

White noise



STASIONER



ADF: $\tau = -7,76$
p-value $< 0,001$
 $\tau < -2,88 \rightarrow$ tolak H_0

AR(1), $\phi_1 = 0,7$



STASIONER



ADF: $\tau = -5,65$
p-value $< 0,001$
 $\tau < -2,88 \rightarrow$ tolak H_0

Random walk



TIDAK STASIONER



ADF: $\tau = -1,34$
p-value $= 0,611$
 $\tau > -2,88 \rightarrow$ gagal tolak H_0

Random walk + drift

TIDAK STASIONER



ADF: $\tau = -1,33$
p-value $= 0,615$
 $\tau > -2,88 \rightarrow$ gagal tolak H_0



Treatment bila tidak stasioner dalam mean: differencing

Sebelum: Z_t (random walk + drift)

TIDAK STASIONER

ADF $\tau = -1,33$, $p = 0,615$

Tren naik, ACF turun sangat lambat.





Sesudah: $W_t = Z_t - Z_{t-1}$

STASIONER

ADF $\tau = -10,82$, $p < 0,001$

Berfluktuasi di sekitar rata-rata $c \approx 0,3$;

ACF langsung masuk batas.




Ringkas: differencing $d = 1$ (atau 2) · seasonal differencing $(1 - B^s)$ untuk pola musiman · detrending bila tren deterministik · cek ulang ACF dan ADF setelahnya.

Model ARIMA musiman (SARIMA)

ARIMA(p, d, q)(P, D, Q)^s

$$\phi(B) \Phi(B^s) (1 - B)^d (1 - B^s)^D Z_t = \theta(B) \Theta(B^s) a_t$$



Pola berulang tiap 12 periode → ACF tinggi pada lag 12, 24, 36, ...

(p, d, q)

Orde non-musiman: AR, differencing, MA

(P, D, Q)

Orde musiman: AR, differencing, MA pada lag s

s

Periode musiman: 12 (bulanan), 4 (kuartalan), 7 (harian)

(1 - B^s)


Seasonal differencing: $Z_t - Z_{t-s}$

Contoh model musiman ($s = 12$)

Model	Notasi	Persamaan	Pola ACF / PACF
AR musiman	$\text{ARIMA}(0,0,0)(1,0,0)^{12}$	$Z_t = \Phi_1 Z_{t-12} + a_t$	PACF terpotong di lag 12
MA musiman	$\text{ARIMA}(0,0,0)(0,0,1)^{12}$	$Z_t = a_t - \Theta_1 a_{t-12}$	ACF terpotong di lag 12
Seasonal random walk	$\text{ARIMA}(0,0,0)(0,1,0)^{12}$	$Z_t = Z_{t-12} + a_t$	ACF turun lambat pada lag 12, 24, ...
Airline model	$\text{ARIMA}(0,1,1)(0,1,1)^{12}$	$(1 - B)(1 - B^{12})Z_t = (1 - \theta_1 B)(1 - \Theta_1 B^{12})a_t$	ACF signifikan di lag 1, 11, 12, 13

Airline model berasal dari analisis data penumpang maskapai oleh Box dan Jenkins dan sering menjadi model awal untuk data bulanan bertren dan musiman.

Time series plot: langkah pertama



Tren

Apakah rata-rata naik atau turun seiring waktu?

Musiman

Adakah pola berulang pada periode tetap (mis. 12 bulan)?

Varians

Apakah lebar fluktuasi berubah seiring waktu?

Pencilan

Adakah pengamatan ekstrem atau perubahan struktur?

ASUMSI UTAMA

Data harus stasioner sebelum dimodelkan

$$E(Z_t) = \mu$$

Mean konstan

$$Var(Z_t) = \sigma^2$$


Varians konstan

$$Cov(Z_t, Z_{t+k}) = \gamma_k$$

Kovarians hanya bergantung lag


Stasioner dalam mean

Stasioner dalam mean



Data berfluktuasi di sekitar satu nilai rata-rata yang konstan (garis putus-putus).

Tidak stasioner dalam mean




Rata-rata bergeser mengikuti tren; ACF turun sangat lambat.

Penanganan: differencing, $W_t = (1 - B)^d Z_t$; umumnya $d = 1$ atau 2 sudah cukup.


Stasioner dalam varians

Stasioner dalam varians



Lebar fluktuasi relatif sama sepanjang waktu (garis oranye: $\pm 2\sigma$).


Tidak stasioner dalam varians



Fluktuasi makin melebar seiring waktu walau rata-ratanya tetap.

Penanganan: transformasi Box-Cox; periksa nilai λ , dan $\lambda = 1$ berarti data sudah stasioner dalam varians.

Tidak stasioner dalam mean dan varians



1. Stabilkan varians: Box-Cox

λ	Transformasi
-1	$1 / Z_t$
-0,5	$1 / \sqrt{Z_t}$
0	$\ln Z_t$
0,5	$\sqrt{Z_t}$
1	Z_t (tanpa transformasi)

2. Stabilkan mean: differencing

Lakukan setelah transformasi, lalu cek ulang plot dan ACF.

Identifikasi orde model dengan ACF dan PACF

Model	ACF	PACF
AR(p)	Turun cepat (eksponensial / sinus teredam)	Terpotong setelah lag p
MA(q)	Terpotong setelah lag q	Turun cepat (eksponensial / sinus teredam)
ARMA(p, q)	Turun cepat	Turun cepat
Belum stasioner	Turun sangat lambat	Lag 1 mendekati 1

Lag dianggap signifikan bila melewati batas $\pm 2/\sqrt{n}$. Beberapa model kandidat biasanya diuji bersamaan.

Indikator stasioneritas dari correlogram ACF dan PACF

Kondisi data	Bentuk ACF	Bentuk PACF	Kesimpulan / treatment
Stasioner	Turun cepat ke nol (eksponensial / sinus teredam) atau terpotong setelah beberapa lag	Turun cepat atau terpotong setelah beberapa lag	Stasioner, $d = 0$; lanjut identifikasi orde p dan q
White noise	Semua lag berada di dalam batas $\pm 2/\sqrt{n}$	Semua lag berada di dalam batas $\pm 2/\sqrt{n}$	Stasioner tetapi tanpa struktur; ARIMA(0, 0, 0)
Tidak stasioner dalam mean (tren / akar unit)	$\hat{\rho}_1 \approx 1$, turun sangat lambat dan hampir linear	Lag 1 ≈ 1 , lag berikutnya kecil	Differencing non-musiman, $d = 1$ (atau 2)
Tidak stasioner musiman	Nilai besar di lag $s, 2s, 3s, \dots$ yang turun sangat lambat	Spike besar di lag s	Seasonal differencing $(1 - B^s)$, $D = 1$
Overdifferencing	$\hat{\rho}_1$ negatif besar ($\approx -0,5$), lalu terpotong	Turun lambat dengan nilai negatif	Kurangi orde differencing

Catatan: ketidakstasioneran dalam varians tidak terlihat di correlogram; periksa time series plot dan gunakan Box-Cox.


Diagnosis orde model non-musiman dari ACF dan PACF

Model	ACF	PACF	Penentuan orde	Contoh
AR(p)	Turun cepat (eksponensial / sinus teredam)	Terpotong setelah lag p	p = lag terakhir yang signifikan pada PACF	PACF signifikan di lag 1 dan 2 → AR(2)
MA(q)	Terpotong setelah lag q	Turun cepat (eksponensial / sinus teredam)	q = lag terakhir yang signifikan pada ACF	ACF signifikan hanya di lag 1 → MA(1)
ARMA(p, q)	Turun cepat setelah lag (q – p)	Turun cepat setelah lag (p – q)	Coba orde kecil: (1,1), (2,1), (1,2); pilih dengan AIC/SBC	ACF dan PACF sama-sama turun → ARMA(1, 1)
ARIMA(p, d, q)	Sebelum differencing turun sangat lambat	Lag 1 $\approx$ 1	d = jumlah differencing hingga stasioner; p, q dari pola setelah differencing	Sesudah d = 1 ACF terpotong di lag 1 → ARIMA(0, 1, 1)
White noise	Tidak ada lag signifikan	Tidak ada lag signifikan	p = 0, q = 0	ARIMA(0, 0, 0) atau random walk bila d = 1

Diagnosis orde model musiman (periode s)

Model	ACF pada lag s, 2s, 3s, ...	PACF pada lag s, 2s, 3s, ...	Penentuan orde	Contoh (s = 12)
AR musiman (P)^s	Turun lambat di lag s, 2s, 3s	Terpotong setelah lag Ps	P = kelipatan s terakhir yang signifikan pada PACF	PACF signifikan di lag 12 saja $\rightarrow (1, 0, 0)^{12}$
MA musiman (Q)^s	Terpotong setelah lag Qs	Turun lambat di lag s, 2s, 3s	Q = kelipatan s terakhir yang signifikan pada ACF	ACF signifikan di lag 12 saja $\rightarrow (0, 0, 1)^{12}$
ARMA musiman (P, Q)^s	Turun di lag musiman	Turun di lag musiman	Coba P, Q $\in \{0, 1\}$; pilih dengan AIC/SBC	Keduanya turun di lag 12, 24 $\rightarrow (1, 0, 1)^{12}$
Perlu seasonal differencing (D)	Besar dan turun sangat lambat di lag s, 2s, 3s	Spike besar di lag s	D = 1, lalu identifikasi ulang	ACF lag 12, 24, 36 $\approx 0,8 \rightarrow D = 1$
Multiplikatif (p, d, q)(P, D, Q)^s	Pola lag awal + pola lag musiman, ada satelit di $s \pm 1$	Pola lag awal + pola lag musiman	p, q dari lag awal; P, Q dari kelipatan s	ACF signifikan di lag 1, 11, 12, 13 $\rightarrow (0, 1, 1)(0, 1, 1)^{12}$

Tahap-tahap pemodelan ARIMA Box-Jenkins



Contoh: model ARIMA(1, 0, 1)

Bentuk umum


$$(1 - \phi_1 B) Z_t = \theta_0 + (1 - \theta_1 B) a_t$$

$$Z_t = \theta_0 + \phi_1 Z_{t-1} + a_t - \theta_1 a_{t-1}$$

Simulasi: $\mu = 20$, $\phi_1 = 0,7$, $\theta_1 = -0,5$, $a_t \sim N(0, 1)$

$$\theta_0 = \mu(1 - \phi_1) = 6$$


$$Z_t = 6 + 0,7Z_{t-1} + a_t + 0,5a_{t-1}$$



Time series plot n = 200 (simulasi) · garis putus-putus: $\mu = 20$ · berfluktuasi stabil di sekitar rata-rata → stasioner, d = 0


ACF dan PACF data contoh

ACF



Turun eksponensial secara perlahan: $\hat{\rho}_1 = 0,86$, $\hat{\rho}_2 = 0,64$, $\hat{\rho}_3 = 0,46$ (dies down).

PACF



Besar di lag 1 (0,86), lalu mengecil dengan tanda bergantian (dies down), bukan terpotong.

Identifikasi: ACF dan PACF sama-sama turun cepat → kandidat ARMA(1, 1), yaitu ARIMA(1, 0, 1). Garis oranye: batas $\pm 2/\sqrt{n} = \pm 0,14$.

Estimasi parameter dan model hasil

Parameter	Nilai sebenarnya	Estimasi	Std. error	p-value
μ (rata-rata)	20	20,30	0,438	< 0,001
ϕ_1 (AR)	0,7	0,756	0,050	< 0,001
θ_1 (MA)	-0,5	-0,525	0,067	< 0,001
σ_a^2 (varians galat)	1	0,995	0,113	—


Model hasil estimasi (MLE) $\cdot \theta_0 = \hat{\mu}(1 - \hat{\phi}_1) = 4,96 \cdot AIC = 576,4$

$$Z_t = 4,96 + 0,756 Z_{t-1} + a_t + 0,525 a_{t-1}$$

Semua parameter signifikan pada $\alpha = 5\%$ dan estimasinya dekat dengan nilai sebenarnya.


Plot error (residual) dan cek diagnostik

Plot residual $\hat{a}_t$



Acak di sekitar nol, varians stabil; garis oranye: $\pm 2\hat{\sigma}_a$.

ACF residual (lag 1–20)



Tidak ada lag yang menonjol keluar batas $\pm 2/\sqrt{n}$.

Ljung-Box: lag 10 $p = 0,135$; lag 20 $p = 0,218 \rightarrow$ residual white noise

Shapiro-Wilk: $W = 0,993$, $p = 0,434 \rightarrow$ residual berdistribusi normal

Contoh musiman: ARIMA(2, 0, 0)(1, 0, 0)¹²

Bentuk umum (multiplikatif)


$$(1 - \phi_1 B - \phi_2 B^2)(1 - \Phi_1 B^{12})(Z_t - \mu) = a_t$$

$$Z_t = \theta_0 + \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \Phi_1 Z_{t-12} \\ - \phi_1 \Phi_1 Z_{t-13} - \phi_2 \Phi_1 Z_{t-14} + a_t$$

Simulasi: $\mu = 50$, $\phi_1 = 0,5$, $\phi_2 = 0,2$, $\Phi_1 = 0,6$, $a_t \sim N(0, 1)$

$$\theta_0 = \mu(1 - \phi_1 - \phi_2)(1 - \Phi_1) = 6$$


$$Z_t = 6 + 0,5Z_{t-1} + 0,2Z_{t-2} + 0,6Z_{t-12} \\ - 0,3Z_{t-13} - 0,12Z_{t-14} + a_t$$



Time series plot $n = 240$ (20 tahun data bulanan, simulasi) · garis putus-putus: $\mu = 50$ · stasioner, dengan keterkaitan antarbulan yang sama tiap tahun


ACF dan PACF data musiman

ACF



Turun perlahan di lag awal dan muncul lagi di lag 12 (0,61) dan 24 (0,40): pola musiman dies down.

PACF



Menonjol di lag 1 (0,62), 2 (0,15), dan 12 (0,46), lalu terpotong; lag 13 (-0,32) efek perkalian.

Identifikasi: PACF terpotong setelah lag 2 → AR(2); terpotong setelah lag musiman 12 → AR musiman (1). Batas $\pm 2/\sqrt{n} = \pm 0,13$.

Estimasi parameter dan model hasil (musiman)

Parameter	Nilai sebenarnya	Estimasi	Std. error	p-value
μ (rata-rata)	50	50,37	0,465	< 0,001
ϕ_1 (AR 1)	0,5	0,479	0,062	< 0,001
ϕ_2 (AR 2)	0,2	0,172	0,069	0,012
Φ_1 (AR musiman)	0,6	0,624	0,055	< 0,001
σ_a^2 (varians galat)	1	0,967	0,090	—

Model hasil estimasi (MLE) $\cdot \theta_0 = \hat{\mu}(1 - \hat{\phi}_1 - \hat{\phi}_2)(1 - \hat{\Phi}_1) = 6,60 \cdot AIC = 689,4$


$$(1 - 0,479B - 0,172B^2)(1 - 0,624B^{12})(Z_t - 50,37) = a_t$$

$$Z_t = 6,60 + 0,479Z_{t-1} + 0,172Z_{t-2} + 0,624Z_{t-12} - 0,299Z_{t-13} - 0,108Z_{t-14} + a_t$$

Semua parameter signifikan pada $\alpha = 5\%$; ϕ_2 paling lemah ($p = 0,012$) tetapi tetap dipertahankan.


Plot error (residual) model musiman

Plot residual $\hat{a}_t$



Acak di sekitar nol dengan varians stabil; garis oranye: $\pm 2\hat{\sigma}_a$.

ACF residual (lag 1–36)



Lag 12 dan 24 tidak lagi menonjol; hanya lag 18 sedikit melewati batas (wajar secara kebetulan).

Ljung-Box: lag 12 $p = 0,905$; lag 24 $p = 0,681 \rightarrow$ residual white noise

Shapiro-Wilk: $W = 0,994$, $p = 0,489 \rightarrow$ residual berdistribusi normal